

## 하계 전력수요 예측을 위한 딥 러닝 입력 패턴에 관한 연구

A Study on Deep Learning Input Pattern for Summer Power Demand Prediction

---

저자 (Authors)	신동하, 김창복 Dong-Ha Shin, Chang-Bok Kim
출처 (Source)	<a href="#">한국정보기술학회논문지 14(11)</a> , 2016.11, 127-134 (8 pages) <a href="#">Journal of Korean Institute of Information Technology 14(11)</a> , 2016.11, 127-134 (8 pages)
발행처 (Publisher)	<a href="#">한국정보기술학회</a> Korean Institute of Information Technology
URL	<a href="http://www.dbpia.co.kr/Article/NODE07058925">http://www.dbpia.co.kr/Article/NODE07058925</a>
APA Style	신동하, 김창복 (2016). 하계 전력수요 예측을 위한 딥 러닝 입력 패턴에 관한 연구. 한국정보기술학회 논문지, 14(11), 127-134.
이용정보 (Accessed)	서울대학교 147.46.138.*** 2018/08/24 12:15 (KST)

---

### 저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

### Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

## 하계 전력수요 예측을 위한 딥 러닝 입력 패턴에 관한 연구

신동하\*, 김창복\*\*

### A Study on Deep Learning Input Pattern for Summer Power Demand Prediction

Dong-Ha Shin\*, Chang-Bok Kim\*\*

#### 요 약

기계학습은 전력계통을 효율적으로 운영할 수 있도록, 에너지 빅 데이터 분석과 전력수요예측을 위한 방법으로 관심을 받고 있다. 본 논문은 R과 텐서플로우의 기계학습 패키지를 이용하여, 전력수요예측을 위한 딥 러닝 입력패턴에 대해서 연구하였다. 딥 러닝에서 입력패턴과 학습률은 전력수요예측에서 가장 중요한 요소이지만 인간이 직접 결정해야하기 때문에, 반복적인 실험에 의해 결정해야한다. 전력수요 예측요소는 당일 전력수요와 상관관계가 있는 평균온도, 체감온도, 불쾌지수를 이용하였다. 결과로서, 일주일간 전력수요와 평균온도 데이터 입력패턴이 전력수요예측에서 가장 좋은 결과를 나타냈다. 또한, 체감온도, 불쾌지수 등의 예측요소를 추가함으로써 좀 더 예측결과를 향상시킬 수 있었다. 향후 연구과제로서 제안 모델은 전력수요예측 향상을 위해 기상 요소 빅 데이터를 이용하고, 보다 적합한 딥 러닝 네트워크 구축이 필요하다.

#### Abstract

The machine learning is receiving attention as a new method for energy big data analysis and power demand prediction to be more effectively operating a power system. In this paper, we study input pattern of deep learning for power demand prediction using machine learning package of R and tensorflow. The input pattern and learning rate in deep learning is the most important factor in power demand prediction. However, the input pattern is because humans have directly determined, must determine by repeated experiment. The factor of power demand prediction was used average temperature, sensible temperature, cooling degree hours, discomfort index. As a result, input pattern power demand and average temperature for one week was obtained the best results about power demand prediction. In addition, we were enhanced to more prediction results by adding the sensible temperature and discomfort index elements. As future research, proposed model need to build more suitable network for deep learning, and need to use of meteorological elements Big Data to improve power demand prediction

#### Keywords

machine learning, deep learning, artificial neural network, power demand prediction, big data, tensorflow

\* 가천대학교 에너지 IT 학과

\*\* 가천대학교 에너지 IT학과 교수(교신저자)

· 접수 일: 2016년 10월 17일

· 수정완료일: 2016년 11월 07일

· 게재확정일: 2016년 11월 10일

· Received: Oct. 17, 2016, Revised: Nov. 07, 2016, Accepted: Nov. 10, 2016

· Corresponding Author: Chang-Bok Kim

Dept. of Energy IT, Gachon University, Gyeonggi-do 461-701, Korea

Tel.: +82-32-446-0695, Email: cbkim@gachon.ac.kr

## I. 서 론

전력계통은 수요와 공급이 동시에 이루어지는 복잡하고 정교한 시스템으로, 실시간으로 안정적인 수요와 공급의 균형을 유지하기 위하여, 정확한 전력수요예측이 필요하다[1]. 그러나 냉난방기기 보급의 확대에 따라, 전력수요의 기상 민감도는 크게 증가하고 있고, 지구 온난화로 인한 기후패턴 변화에 따라, 전력수요예측의 어려움이 더욱 증가하고 있다. 따라서 정확한 수요예측을 위해서는 다양한 환경요소에 적응할 수 있는 새로운 수요예측 방법론에 대한 연구가 필요하다[2]. 전력수요예측은 온도, 습도, 풍속, 불쾌지수, 체감온도 등 다양한 기상요소를 이용하며, 이 중에서 온도는 가장 중요한 요소로 전력수요예측에 가장 많이 사용하고 있다[3]-[5]. 최근 다양한 기계학습(Machine Learning) 알고리즘을 이용하여, 효율적으로 전력수요예측을 수행하고자 하는 연구들이 진행되고 있다[6]. 기계학습은 컴퓨터가 데이터를 학습하여 지능을 획득하는 학문분야이며, 빅 데이터(Big Data)의 핵심 기술 분야이다.

딥 러닝(Deep Learning)은 인간의 뇌 구조를 모방한 기계학습이며, 기존 인공신경망(Artificial Neural Network)의 문제점을 개선하여, 영상인식, 음성인식, 자연어 처리, 미래 예측 등 다양한 영역에서 사용되고 있다[7]. 딥 러닝은 다른 형태의 기계학습과는 달리 입력 데이터의 특징 패턴을 그대로 학습하기 때문에, 학습 이전에 입력 데이터의 특징 패턴에 따라 예측 결과가 큰 차이가 있다. 그러나 인공신경망을 이용한 전력수요예측에 대한 연구에서, 전력수요 예측요소의 입력패턴에 관련된 연구가 미비하였다.

본 연구는 R과 텐서플로우(Tensorflow)를 이용하여 딥 러닝 기반 전력수요예측 방법에 대해서 연구하였다. R은 통계 및 그래픽 등을 위한 오픈소스 패키지로서, 빅 데이터 분석목적으로 각광을 받고 있으며, 5000개가 넘는 패키지들이 다양한 기능과 최신 알고리즘을 제공하고 있다[8][9]. 텐서플로우는 구글이 개발자, 데이터 과학자, 연구자들을 위해 오픈소스로 공개한 기계학습 시스템으로, 현재 깃 허브(Git Hub)에서 가장 활발하게 개발 중인 오픈소스 프로젝트이다[10].

본 연구는 전력수요예측을 위해 평균온도, 최저온도, 최고온도, 불쾌지수, 체감온도, 냉방도시 등 다양한 전력수요 예측요소들과 전력수요량의 관계에 대해서 분석하였으며, 딥 러닝의 효율적인 입력 패턴에 대해서 연구하였다. 학습 데이터는 기상 민감도가 가장 높은 2009년도에서 2014년도 하계 데이터를 사용하였으며, 예측을 위한 테스트 데이터는 2015년도 하계 데이터 중 일부를 사용하였다. 기계학습 알고리즘은 R의 neuralnet 패키지를 이용한 단층 인공신경망 그리고 텐서플로우는 이용한 딥 러닝을 사용하였다. 본 논문은 2장에서 관련연구로서 전력수요 예측요소와 기계학습에 대해서 서술하였으며, 3장에서 전력수요 예측모델을 제안하였으며, 4장에서 연구 결과를 나타내고 마지막으로 결론에 대해서 서술하였다.

## II. 관련 연구

### 2.1 전력수요 예측요소

동하계 전력은 냉난방 부하가 전체 전력수요의 20-25% 수준을 차지하고 있으며, 이를 위해 동하계 전력수요예측은 냉난방 부하에 민감한 평균온도, 습도, 풍속, 체감온도, 냉방도시, 불쾌지수 등 다양한 기상요소를 이용한다. 전력수요 예측요소는 온도가 가장 중요한 요소로, 전력수요량과 온도변화를 기반으로 전력수요예측을 수행한다. 전국의 당일온도는 각 지역마다 차이가 있기 때문에, 보다 정확한 전력수요예측을 위해서는 대표온도를 산출해야 할 필요가 있다. 대표온도는 지역온도와 수요분포 가중치를 이용하여 산출할 수 있다. 수요분포 가중치는 각 지역의 전력 판매량과 인구를 이용하여 산출한다. 다음은 대표온도를 산출하는 식이다. 또한, 표 1에 지역 전력수요 가중치에 대해서 나타냈다[3].

$$\begin{aligned} \text{대표온도} = & \text{서울온도} \times \text{서울수요분포가중치} + (1) \\ & \text{대전온도} \times \text{대전수요분포가중치} + \\ & \text{대구온도} \times \text{대구수요분포가중치} + \\ & \text{광주온도} \times \text{광주수요분포가중치} + \\ & \text{부산온도} \times \text{부산수요분포가중치} \end{aligned}$$

표 1. 지역 전력수요 가중치

Table 1. Regional power demand weight

지역	서울	대전	대구	광주	부산
가중치	50.0	10.0	12.0	8.0	20.0

동하계는 습도나 풍속을 포함하는 온도지표인 체감온도를 사용하여, 전력수요자가 실제로 느끼는 온도를 사용하는 것이 전력수요예측에 좀 더 효과적인 방법일 수 있다. 체감온도는 풍속과 습도로 산출할 수 있으며, 풍속을 이용하면 풍속 증가에 따라 체감온도가 내려가고, 습도를 이용하면 습도 증가에 따라 체감온도가 올라간다. 일반적으로 풍속은 겨울의 체감온도를 산출하는 경우에 사용하고, 습도는 여름의 체감온도를 산출할 때 사용한다. 즉, 추운 겨울에는 풍속이 증가함에 따라 느끼는 온도는 더욱 내려가고, 여름에는 고온의 공기가 땀의 증발에 의한 체온 조절기능으로 습도가 올라갈수록 체감온도는 더욱 올라가게 된다. 습도 및 풍속을 이용한 체감온도는 다음과 같다.

$$\text{체감온도} = T - 0.4 \times (T - 10) \times (1 - H) \quad (2)$$

$$\text{체감온도} = 13.12 + 0.6215 \times T - 11.37 \times V^{0.16} + 0.3965 \times V^{0.16} \times T \quad (3)$$

여기서 T는 온도(°C), V(km/h)는 풍속, H(%)는 습도이다.

전력수요 민감도는 온도(°C) 변화량에 따른 전력수요량(MW)을 나타낸다. 하계에는 온도가 높아질수록 전력수요가 증가하는 양의 상관관계, 동계에는 온도가 낮아질수록 전력수요가 증가하는 음의 상관관계를 가지게 된다. 그러나 온도가 지속적으로 높게 또는 낮게 나타내는 냉난방 집중기간에는 온도와 전력수요의 상관관계가 줄어들어 전력수요를 예측하기 어려운 현상이 발생한다. 실제로 하계 8월과 동계 1월의 전력수요와 온도의 상관관계는 매우 낮게 나타난다. 이와 같이 냉난방부하는 같은 온도에 항상 같은 부하가 나타나는 것이 아니라 그 이전의 전력수요자의 경험에 따라서 달라진다. 이때 지속적인 온도의 누적을 나타내는 냉방도시 또는 냉방도

Degree Hours)는 하루를 기준으로, 냉방도일(Cooling Degree Days)은 한 달을 기준으로 평균온도에 냉방도시 기준온도를 뺀 수치이다. 냉방도시는 다음과 같이 나타낸다.

$$T_{d,h} = \sum_{i=1}^n [T_h(i) - 18] \quad (4)$$

여기서  $T_h(i)$ 는  $i$  시간의 온도이며, 냉방도시 기준온도는 18°C 또는 24°C이다.

불쾌지수는 날씨에 따라서 사람이 불쾌감을 느끼는 정도를 온도와 습도를 이용하여 나타내는 수치로서, 명백한 기준은 아니지만 70 이상인 경우에는 약 10%의 사람이 불쾌감을 느낀다고 하며, 75인 경우에는 약 50%의 사람이, 80 이상인 경우에는 대부분의 사람이 불쾌감을 느낀다. 불쾌지수는 다음과 같은 식으로 산출한다.

$$DI = 1.8 \times T - 0.55 \times (1 - RH) \times (1.8 \times T - 26) + 32 \quad (5)$$

여기서 DI는 불쾌지수, T는 온도(°C)이며, RH는 상대 습도이다.

## 2.2 기계학습

기계학습은 컴퓨터에게 학습능력과 지능을 주는 학문분야이며, 인공지능망은 인간의 뇌 구조를 모방한 기계학습이다. 기존의 인공지능망은 뇌의 뉴런과 유사한 형태인 시그모이드(Sigmoid) 비선형 함수를 사용하였다.

시그모이드는 지수함수의 특징 때문에, 미분을 통한 기울기 감소법으로 가중치를 수정하여 비용함수 최소화 과정에서, 지역 극소값 문제에 의해 최적화에 실패할 수 있다. 또한, 함수값을 [0, 1]로 제한하기 때문에, 중간층을 다층으로 구성하였을 경우, 이전의 기울기와 현재 기울기를 곱해서 에러를 전파하는 역전파 학습 특성에 의해 기울기가 사라져 버릴 위험성이 크다.

딥 러닝은 ReLu(Rectified Linear Unit), Leaky ReLU 등 활성화 함수를 통해, 지역 극소값, 기울기

사라짐 문제 등을 제거하고, 초기 가중치를 학습에 용이하게 초기화하는 RBM(Restricted Boltzmann Machine), Xavier 등의 알고리즘을 통해, 중간층을 깊게 구성할 수 있는 인공신경망이다[11]. 그림 1에 시그모이드와 ReLu 활성화 함수에 대해서 나타냈다.




그림 1. 활성화 함수  
Fig. 1. Activation function

딥 러닝은 CNN(Convolution Neural Networks)과 RNN(Recurrent Neural Networks) 등 다양한 네트워크를 이용하여, 영상, 음성, 자연어 처리뿐 아니라 예측, 군집, 분류, 추천, 무인시스템, 게임 등 다양한 영역에 사용되고 있다.

텐서플로우는 구글이 개발자, 데이터 과학자, 연구자들을 위해 오픈소스로 공개한 기계학습 시스템으로, 데이터 플로우 그래프를 사용해서 연산을 하는 라이브러리이다. 그래프의 노드(Node)는 미분과 같은 다양한 연산을 나타내고, 노드를 연결하는 그래프의 에지(Edge)는 텐서(Tensor)라 불리는 다차원 데이터 배열이다. 즉, 다차원 배열에 저장된 데이터를 다양한 연산을 통해 기계학습을 하는 것이다. 텐서플로우는 파이썬(Python) 및 C++ 그리고 SWIG [12]를 통해 다양한 언어 지원하며, 데이터 플로우 그래프를 통한 풍부한 표현력, 연산구조와 목표 함수만 정의하면 자동으로 미분 계산을 처리 등의 특징이 있다.

### III. 전력수요 예측모델

딥러닝을 이용한 전력수요예측은 데이터 입력패턴과 학습률에 따라 학습과 예측결과의 정확성이 달라지며, 적절한 입력패턴과 학습률을 직접 선택해야 한다. 본 연구는 평균온도, 불쾌지수, 체감온도 등 전력수요 예측요소들과 전력수요량과의 관계에

대해서 분석하여, 보다 정확도가 높은 전력수요예측 입력패턴을 제안하였다. 이를 위해 R을 이용하여, 기존 전력수요 데이터와 온도, 습도, 풍속, 불쾌지수, 체감온도, 냉방도시 등 다양한 전력수요 예측요소 데이터에 대한 상관관계를 분석하고, 기존의 단층 인공신경망에 대한 전력수요예측을 위한 입력패턴을 분석하였다. 또한, 분석 결과 중에서 보다 좋은 전력수요예측을 보인 입력패턴, 노드수, 전력수요 환경요소를 이용하여 텐서플로우로 딥 러닝을 구축하여 실행하였다. 표 2에 2009년도부터 2015년도까지 하계 전력수요와 전력수요 예측요소인 평균온도, 불쾌지수, 냉방도시, 체감온도의 상관관계에 대해서 나타냈다.

표 2. 전력수요와 예측요인 상관관계

Table 2. Correlation of power demand and prediction elements

	온도	불쾌지수	냉방도시	체감온도
7월 전체	0.609	0.649	0.630	0.653
8월 전체	0.419	0.439	0.401	0.388
전체	0.486	0.528	0.485	0.5296

표 2에서 당일전력은 평균온도, 불쾌지수, 냉방도시, 체감온도와 상관관계가 높았다. 또한, 당일전력과 평균온도보다 당일전력과 불쾌지수 및 체감온도가 상관관계가 높았지만, 각 연도별 및 월별로 차이가 있었다. 예를 들어, 2013년도 7월은 당일전력과 전력수요 예측요소의 상관관계가 매우 낮았으며, 원인은 많은 비와 바람과 같은 기상요소에 있었다. 표 2에서 전력수요와 평균온도, 불쾌지수, 냉방도시, 체감온도의 상관관계를 비교하였을 때, 7월의 상관관계가 8월의 상관관계보다는 매우 높게 나타났다. 8월이 상관관계가 낮은 것은 1년 중 냉방도일이 가장 높기 때문이다.

본 논문은 입력패턴 실험을 통해, 일주일간의 전력수요데이터와 기상요소데이터의 입력패턴과 다음날 전력수요데이터를 예측 수요데이터로 사용하는 모델을 제안하였다. 그림 2에 본 논문에서 제안한 딥 러닝 모델의 입력패턴에 대해서 나타냈다. 그림 2에서 d0는 당일 수요전력이며, d6는 6일전 수요전력이다. 마찬가지로 T1은 당일 평균온도이며, T7은

6일전 평균온도이다. 또한, S와 D는 다음날의 체감 온도와 불쾌지수이며, 출력층의 dd는 다음날의 전력 수요데이터로서 학습을 위한 레이블이다.

딥 러닝의 입력은 작은 데이터를 이용하여, 학습 및 테스트를 하여야 효율적이기 때문에, 입력에 사용되는 전력수요 예측요소 데이터를 다음과 같이 정규화하여, 0부터 1사이의 값을 사용하였다

$$\text{정규화} = \frac{\text{요소값} - \text{최소값}}{\text{최대값} - \text{최소값}} \quad (6)$$

여기서 요소값은 전력수요, 평균온도, 불쾌지수, 냉방도시, 체감온도 등이다. 또한, 전력수요 예측 값 역시 큰 데이터인 경우에는 학습에 문제가 있었으며, 수요예측 값에 1000또는 10000을 나누어서 실험하였다. 다음은 R 코드의 일부이다.

```
elec_train<-elec_norm[1:172,]
elec_test<-elec_norm[173:179,]
elec_model<-neuralnet(dd~d7+d6+d5+d4+d3+d2+d1+T6+T5+T4+T3+T2+T1+T0,data=elec_train,
hidden=128)
model_results<-compute(elec_model,elec_test[1:14])
prdeicted_elec<-model_results$net.result
cor(prdeicted_elec,elec_test$dd)
```

R에서 전체 데이터를 2009년도부터 2014년도까지를 학습데이터, 2015년도 데이터 중 일주일 데이터를 테스트 데이터로 하여 분리하였다. 여기서 본 연구에서는 상관관계가 매우 낮은 2013년도 7월 데이터는 제외하였다. 또한, 학습데이터를 이용하여 R의 인공신경망 패키지인 neuralnet을 통해 학습하여, 학습모델 elec\_model을 생성한 후, 테스트 데이터를 이용하여, 상관관계 및 예측결과를 분석하였다. 다음은 딥 러닝 텐서플로우 코드의 일부분이다.

```
n_hidden_1 = 128
def multilayer_perceptron(x, weights, biases):
    layer_1 = tf.add(tf.matmul(x, weights['h1']),
    biases['b1'])
    layer_1 = tf.nn.relu(layer_1)
    out_layer = tf.matmul(layer_1, weights['out']) +
    biases['out']
    return out_layer
pred = multilayer_perceptron(x, weights, biases)
cost = tf.reduce_mean(tf.square(pred-y))
op = tf.train.AdamOptimizer(learning_rate=0.01).
minimize(cost)
```

본 논문은 중간층을 5, 16, 64, 128, 256 노드로 실험하여, 결과가 가장 좋은 128개의 노드로 설정하였으며, 활성화 함수로 ReLU 함수를 이용하였다.

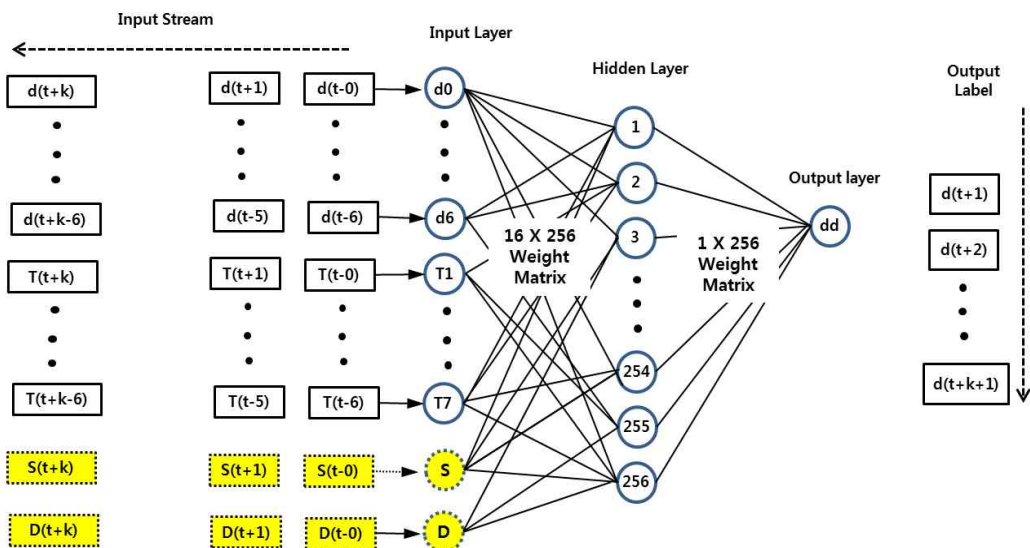


그림 2. 제안 딥 러닝 모델  
Fig. 2. Proposed deep learning model

코드에서는 중간층을 1층으로 하였으나, 중간층을 늘려가면서 실험을 하였다. 오차율을 나타내는 비용함수는 다음과 같다.

$$\text{cost}(w, b) = \frac{1}{m} \sum_{i=1}^m (\text{pred}(x_i) - \text{actual}(x_i))^2 \quad (7)$$

여기서  $\text{pred}(x_i)$ 는 출력노드  $i$ 에 대한 예측값이며,  $\text{actual}(x_i)$ 는 출력노드  $i$ 에 대한 실제값이다.

최적화 알고리즘은 기울기 감소 최적화인 GradientDescentOptimizer보다 최적화 속도가 빠른 AdamOptimizer를 사용하였다. 학습률은 0.1에서 0.01 사이의 값을 반복 사용하였다. 그림 3에 텐서플로우 코드의 전체 모델구조를 텐서보드를 이용하여 나타냈다.

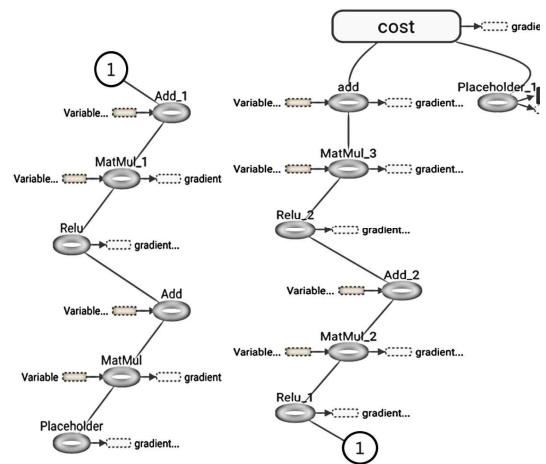


그림 3. 텐서보드 그래프  
Fig. 3. Tensor board graph

#### IV. 실험 결과

본 연구의 실험환경은 리눅스 우분투 운영체제, Mac OS Sierra 운영체제, 통계 오픈소스인 R, 파이썬(Python) 2.7기반 텐서플로우를 이용하였다. 그림 4에 R의 실험결과 중에서 중간층이 5노드인 인공신경망에 대해서 나타냈다.

그림 5에 전력수요량, 평균온도, 불쾌지수, 체감온도 등 모든 수요예측 환경요소가 포함되고, 중간층이 128노드인 경우의 실제 예측결과에 대해서 나타냈다.

그림 5에서 `cor(predicted_elec, elec_test$dd)`은 예측 전력수요 데이터와 실제 전력수요 데이터에 대한 상관관계로서 0.947이라는 높은 상관관계를 보였다. `elec_test$dd`는 실제 전력수요량이며, `predicted_elec`는 예측 전력수요량이다. 표 3에 R을 이용한 128노드의 다층 인공신경망 전체 결과를 나타냈다.

결과 1은 전력수요량과 온도만을 이용한 결과이며, 결과 2는 체감온도 포함, 결과 3은 불쾌지수 포함, 결과 4는 체감온도와 불쾌지수를 모두 포함한 것이며, 그림 5의 결과값이기도 하다. 오차율은 평균제곱오차(Mean Square Error)를 이용하였다.

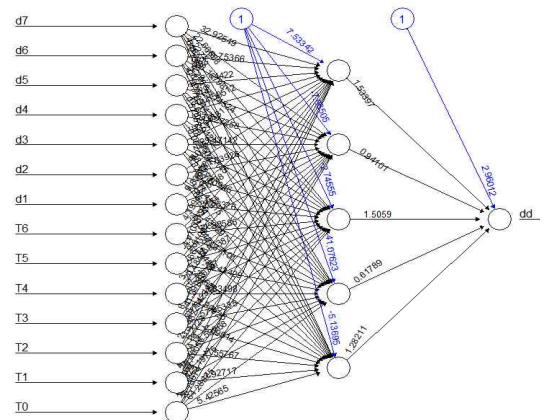


그림 4. 인공신경망 구조  
Fig. 4. Artificial neural network structure

```
> cor(predicted_elec, elec_test$dd)
      [,1]
[1,] 0.9471454168

> elec_test$dd
[1] 6.4202 6.0454 7.3976 7.6179 7.4624 7.6696 7.4429

> predicted_elec
      [,1]
173 6.656068979
174 5.861564619
175 7.144964303
176 7.269637182
177 7.538276091
178 7.738593866
179 7.450959231
```

그림 5. 실제 실행결과(128 노드)  
Fig. 5. Actual execution result(128 node)



표 3. 단층 인공 신경망 전체 결과

Table 3. Single layer artificial neural network total results

실제값	예측 결과 1	예측 결과 2	결과 예측 3	예측 결과 4
6.4202	6.603	6.3581	6.517	6.6561
6.0454	5.901	5.7825	5.871	5.8616
7.3976	7.27	6.9771	6.943	7.145
7.6179	7.233	7.522	7.407	7.2696
7.4624	7.522	7.5887	7.536	7.5383
7.6696	7.34	7.7929	7.476	7.7386
7.4429	7.759	7.7455	7.49	7.451
오차률	0.062	0.0545	0.048	0.0407

표 3에서 학습할 때 마다 다소의 차이가 있었으나, 전력수요량과 온도만을 이용한 결과보다는 체감온도 또는 불쾌지수를 포함하거나, 체감온도와 불쾌지수를 모두 포함하여 학습한 결과가 오차율이 낮았다. 텐서플로우는 R의 실행 결과 온도, 체감온도, 불쾌지수를 모두 포함한 128노드의 인공신경망에 중간층을 증가하면서 실행하였다. 그림 6에 128 노드를 가지며, 중간층이 3층인 경우의 실제 예측결과에 대해서 나타냈다.

표 4에 텐서플로우를 이용한 다층 신경망 결과를 나타냈다. 표 4에서 알 수 있듯이 단층인 1층에서 보다는 2층, 3층의 예측결과가 다소 향상되었다.

```

Optimization Finished!!!!!!!!!!!!!!!!!!!!!!
last train cost 0.0499853
cost is under 0.05
#####
test result
actual value [[ 6.4202]
[ 6.0454]
[ 7.3976]
[ 7.6179]
[ 7.4624]
[ 7.6696]
[ 7.4429]]
predit value [[ 6.50821877]
[ 6.05964088]
[ 7.32857704]
[ 7.47188759]
[ 7.49321747]
[ 7.3013401 ]
[ 7.43256569]]
test_cost 0.0243865
#####
deep 10 -> start time 2016-10-11 22:26:57.712811
deep 10 -> last time 2016-10-11 22:29:00.961637
the end

```

그림 6. 텐서플로우 실행결과

Fig. 6. Execution result in Tensorflow

표 4. 중간층 수에 대한 실행 결과

Table 4. Execution result for number of hidden layer nodes

실제값	1층	2층	3층
6.4202	6.3505	6.1925	6.5082
6.0454	5.9111	6.2388	6.0596
7.3976	6.9844	7.2762	7.3286
7.6179	7.3003	7.3611	7.4719
7.4624	7.509	7.4538	7.4932
7.6696	7.5406	7.6158	7.3013
7.4429	7.4241	7.6951	7.4326
오차률	0.0448	0.0338	0.024

본 연구의 실험 결과 일주일간의 전력수요량과 평균온도 그리고 불쾌지수, 체감온도 등 모든 수요 예측 환경요소가 포함되고, 중간층이 128노드인 경우가 예측결과가 좋았다. 또한, 딥 러닝에서 1층보다는 2층과 3층의 예측결과가 좋았다. 그러나 학습 데이터량 적은 데 비해 중간층의 노드수가 많아지거나 중간층의 깊이가 늘어나면 오히려 예측률이 감소되는 현상이 있었다.

## V. 결론 및 향후 과제

본 연구는 전력수요량과 다양한 전력수요 예측요소들의 관계에 대해서 분석하고, 전력수요예측을 위한 딥 러닝의 입력패턴에 대해서 연구하였다. 연구 결과로서, 일주일치의 전력데이터와 기상요소들을 입력패턴으로 한 결과가 가장 예측결과가 좋았다. 또한, 온도 뿐 아니라 습도, 풍속 등 다양한 기상요소를 이용하여, 체감온도, 불쾌지수 예측 요소를 추가함으로써, 예측결과를 향상시킬 수 있었다.

본 연구에서 인공신경망의 학습할 때 마다 학습결과에 다소 많은 차이가 있었으며, 중간층의 노드수가 많아지거나, 중간층의 깊이가 늘어나면 오히려 학습률이 감소되는 현상이 있었다. 이것은 적은 학습데이터량과 과잉학습으로 인한 오버피팅(Overfitting)으로 판단된다.

향후 이러한 문제를 해결하고, 전력수요 예측결과를 향상하기 위해, 보다 방대한 기상 빅 데이터를 이용하고, 효율적인 딥 러닝 네트워크 구축하고, 정규화를 통한 Dropout 방법 등에 대한 연구가 필요하다.



## References

- [1] B. G. Koo, H. S. Kim, H. S. Lee, and J. Ho Park, "Short-term Electric Load Forecasting for Summer Season using Temperature Data", The Transactions of the Korean Institute of Electrical Engineers, Vol. 64, No. 8, pp. 1137-1144, Aug. 2015.
- [2] Y. T. Son, "Thoughts on Artificial Intelligence and Power Industry", Korea electric association, Journal of Electrical World Monthly Magazine, pp. 70-70, Apr. 2016.
- [3] S. I. Kong, Y. S. Baek, K. B. Song, and J. H. Park, "The Daily Peak Load Forecasting in Summer with the Sensitivity of Temperature", The Transactions of the Korean Institute of Electrical Engineers, Vol. 53(A), No. 6, pp. 538-363, Jun. 2004.
- [4] D. H. Ahn, K. H. Song, and E. J. Choi, "The Research for the Change of Load Demand in Wintertime by the Influence of a Climate", Journal of the Korean Institute of Illuminating and Electrical Installation Engineers, Vol. 23, No. 9, pp. 47-54, Sep. 2009.
- [5] K. S. Kim, G. H. Ryu, and K. B. Song, "Short-term Load Forecasting of Using Data refine for Temperature Characteristics at Jeju Island", The Transactions of the Korean Institute of Electrical Engineers, Vol. 58, No. 9, pp. 1695-1699, Sep. 2009.
- [6] M. K. Kim and C. E. Hong, "The Artificial Neural Network based Electric Power Demand Forecast using a Season and Weather Informations", The Transactions of the Korean Institute of Electrical Engineers, Vol. 53, No. 1, pp. 71-78, Jan. 2016.
- [7] S. M. An, "Deep Learning Architectures and Applications", Korea intelligent information system society, intelligent information study, Vol. 22, No. 2, Jun. 2016.
- [8] <https://cran.r-project.org/>, [Accessed: Aug. 13. 2016]
- [9] [http://www.openstatistics.net/doc/contributed/2013/Er-ic-R-Data-Mining-20130812\\_v3.pdf](http://www.openstatistics.net/doc/contributed/2013/Er-ic-R-Data-Mining-20130812_v3.pdf), [Accessed: Aug. 13. 2016]
- [10] J. Torres, "First Contact with tensorflow", Hanbit Meadia, 2016.
- [11] H. Geoffrey, S. Osindero, and Y. W. Teh. "A fast learning algorithm for deep belief nets", Neural computation, Vol. 18. No. 7, pp. 1527-1554, May 2006.
- [12] <http://www.swig.org>, [Accessed: Sep. 21. 2016]

## 저자소개

### 신 동 하 (Dong-Ha Shin)



2016년 2월 : 가천대학교  
에너지IT학과(공학사)  
2016년 3월 ~ 현재 : 가천대학교  
IT융합공학과(석사 과정)  
관심분야 : 딥러닝, 빅 데이터,  
IOT, 로봇제어, 로봇 액추에이터

### 김 창 복 (Chang-Bok Kim)



1986년 2월 : 단국대학교  
전자공학과(공학사)  
1989년 2월 : 단국대학교  
전자공학과(공학석사)  
2009년 2월 : 인천대학교 컴퓨터  
공학과(공학박사)  
1994년 ~ 현재 : 가천대학교  
IT대학 에너지 IT학과 교수  
관심분야 : 데이터 마이닝, 분산처리시스템, IOT,  
홀로그래프